

软件

开发

工作坊 II

关于课程项目

内容

- 时间线

- 分组

- 项目格式

- 数据集

- 演示

- 评分

时间线

- 项目发布（3 月 25 日）
- 小组选择（截止日期：4 月 1 日）
- 提交软件开发规范（截止日期：4 月 22 日）
- 提交初稿实现（截止日期：5 月 13 日）

时间线

- 提交最终版（V2）实现与报告（截止日期：5 月 20 日）

☒ 报告中请注明每位成员对项目的总体贡献百分比

- 演示（5 月 25-29 日）

☒ 演示在各班级的实验课时间内进行

注意：SDS 和报告的模板已在 iSpace 上提供

分组

- 每组最多可有 6 名成员（若属于最后几组，则可为 5 人）。
- 请自行组队，并在 iSpace 上注册小组。
- 小组选择截止日期为 4 月 1 日。若未在截止日期前注册，我们将为您分配至未满员的小组。
- 请为小组选定一名组长。组长仅作为联络人，无额外职责。

项目格式

- 目标

对真实世界数据集进行数据处理

- 为你提供了 5 个数据集——探索、分析并从中获取洞见

- 自行选择关注重点

你将从中挑选一个数据集，并决定如何处理该数据集

你的组成部分

工作

你的工作必须包含以下组成部分。

1: 数据探索与清洗

- 将数据集加载到 Python 环境（如 Jupyter Notebook）中。
- 进行初步探索，以了解数据结构、变量及潜在问题（如缺失值、重复项、不一致性）。
- 通过处理缺失值、删除重复项和纠正不一致性来清理数据集。

2：数据分析

- 进行探索性数据分析（EDA），以揭示数据中的模式、趋势和关系。
- 运用统计方法和可视化手段来支撑你的发现。
- 从数据集中提炼出至少若干见解。

3：数据可视化

- 创建有意义的可视化图表来展示你的发现。
- 确保可视化图表标注清晰，易于解读。

4：高级任务（可选）

- 构建机器学习模型（例如分类、回归、聚类）。

- 执行时间序列分析或地理空间分析。

5 个数据集

你必须从以下 5 个数据集中选择一个。

1: COVID-19 数据集

- 包含全球 COVID-19 数据，包括病例数、死亡数、康复数及疫苗接种率。
- 使用场景：数据清洗、时间序列分析、趋势可视化及区域对比。
- 数据来源：Our World in Data

2: FIFA 球员数据集

- 包含 FIFA 球员的详细信息，包括评分、位置和技能。
- 使用场景：数据清洗、球员表现分析、球队组建及可视化。
- Kaggle FIFA 数据集

3: 宝可梦数据集

- 包含宝可梦的信息，包括属性、类型和能力。

- 使用场景：数据清洗、类型分析和可视化。

- Kaggle 宝可梦数据集

4: IMDB 电影数据集

- 包含 2017 年 7 月及之前上映的电影。数据点包括演员、剧组、剧情关键词、预算、票房、海报、上映日期、语言、制作公司、国家、TMDB 投票数和平均评分。

- 应用场景：数据清洗、类型分析、评分趋势及可视化。

- Kaggle IMDB 数据集

5: 人类活动识别数据集

- 包含手机中 IMU 传感器的数据和标签，包括传感器信号、训练集、测试集及对应的标签。

- 应用场景：数据清洗、模型训练和可视化。

- UCI HAR 数据集

演示

- 演示时长：8 - 10 分钟
- 小组每位成员均需发言。
- 建议每位成员介绍自己负责的部分。
- 部分成员发言时间可稍长，但所有人都必须发言。

演示

- 如果英语表达不够流利，可以通过优化幻灯片来弥补。
- 请在 PPT 中，将你的名字标注在你发言的幻灯片上。
- 请在幻灯片上显示页码。
- 在演示开始前，请向老师提交两份打印版的 PPT。

每页至少打印 4 张幻灯片！

评分

- 完成提交后，您将在初版 SDS 和初版实现中获得满分。(5%)

- 其余评估基于您的演示和最终提交。(95%)

- ☐ 请参考评分标准了解详情。

- ☐ 如果您对项目做出合理贡献，您将在团队合作中获得满分。

- ☐ 例如，若小组人数为 5 人，则贡献度约为 20%。